ANHANGUERA

MICHELA JULIANA OLIVEIRA

MATRICULA- 2025369608

RELATÓRIO DE ATIVIDADE PRATICA

Unidade 4 - Aplicações Com Python

SERTÃOZINHO -SP

2025

MICHELA JULIANA OLIVEIRA
MATRICULA- 2025369608

RELATÓRIO DE ATIVIDADE PRATICA

Unidade 4 - Aplicações Com Python

Trabalho apresentado ao curso de Engenharia de Software, como requisição para obtenção de nota para disciplina de Linguagem De Programação.

SERTÃOZINHO -SP
2025

SUMARIO

1. *INTRODUÇÃO* ____ *4*
2. *OBJETIVO* ____ *5*
3. *METODOLOGIA E DESENVOLVIMENTO* ____ *6*
4. *CONCLUSÃO* ____ *17*
5. *REFERENCIAS BIBLIOGRAFIAS* ____ *18*

1. INTRODUÇÃO

Este relatório descreve a execução da aula pratica da disciplina: Linguagem De Programação da Unidade: 4 – Aplicações Com Python na Aula: 4 – Machine Learning Com Python.

A área de Machine Learning, ou aprendizado de máquina, foi desenvolvida para que computadores possam desempenhar tarefas a partir de dados, sem serem explicitamente programados para executar determinada ação. Isso ocorre por meio do treinamento do computador com grandes volumes de dados, nos quais a máquina identifica padrões, tornando possível realizar previsões ou tomar decisões com base nesses dados, sem que seja necessário desenvolver um conjunto fixo de instruções. Essa área é muito importante para a automatização de tarefas e está cada vez mais presente em nosso dia a dia (AMÍLCAR NETTO; MACIEL, 2021).

2. OBJETIVO

A aula pratica tem o objetivo de compreender como utilizar a linguagem Python para compreender os conceitos de machine learning e realizar técnicas de machine learning com Python.

3. METODOLOGIA E DESENVOLVIMENTO

Atividade proposta: Você foi contratado para criar um modelo de Machine Learning que classifica espécies de flores Iris com base em características como comprimento e largura das sépalas e pétalas. Você usará o TensorFlow para construir, treinar e avaliar o modelo.

Passo 1: Importar Bibliotecas e Carregar Dados

• Usar bibliotecas como tensorflow, pandas e scikit-learn.

• Carregar o conjunto de dados Iris disponível no scikit-learn.

```
# Importar bibliotecas
import tensorflow as tf
import pandas as pd from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

2 # Carregar conjunto de dados
Iris iris = load_iris()
 X = iris.data
y = iris.target
```

Passo 2: Pré-processamento dos Dados

• Dividir o conjunto de dados em treinamento e teste.

• Normalizar os dados.

Passo 3: Construir o Modelo

• Usar TensorFlow para construir um modelo de rede neural simples.

Passo 4: Treinar o Modelo

• Treinar o modelo com os dados de treinamento

Passo 5: Avaliar o Modelo

• Avaliar a precisão do modelo usando os dados de teste.

Passo 6: Fazer Previsões

• Fazer previsões com o modelo treinado

Procedimentos para a realização da atividade:

• Acesse o Google Colab e crie um novo notebook

. • Implemente as funcionalidades solicitadas usando as instruções e dicas fornecidas.

• Teste o código com diferentes entradas para garantir que ele está funcionando corretamente.

• Comente o código para explicar cada parte da lógica implementada.

A seguir está o código completo:

```
# Passo 1: Importar Bibliotecas e Carregar Dados
# Importando o que vamos usar: TensorFlow para o modelo, Scikit-learn para dados e pré-processamento.
import tensorflow as tf
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
import numpy as np

# Carregando a base de dados Iris. 'X' são as características, 'y' são as espécies.
iris = load_iris()
X = iris.data
y = iris.target

# Passo 2: Pré-processamento dos Dados
# Dividindo os dados em conjuntos de treino e teste (80/20).
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Normalizando os dados para que fiquem na mesma escala.
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
```

```
X_test = scaler.transform(X_test)

# Passo 3: Construir o Modelo
# Criando um modelo de rede neural simples com o Keras.
model = tf.keras.Sequential([
    # Camada de entrada com 10 neurônios e ativação 'relu'.
    tf.keras.layers.Dense(10, activation='relu', input_shape=(X_train.shape[1],)),

    # Camada de saída com 3 neurônios (uma para cada espécie) e ativação 'softmax'.
    tf.keras.layers.Dense(3, activation='softmax')
])

# Compilando o modelo. Usando 'adam' como otimizador e 'accuracy' como métrica.
model.compile(
    optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy']
)

# Passo 4: Treinar o Modelo
# Treinando o modelo por 50 épocas.
print("Treinando o modelo...")
history = model.fit(X_train, y_train, epochs=50, validation_data=(X_test, y_test))

# Passo 5: Avaliar o Modelo
# Avaliando a performance no conjunto de teste.
loss, accuracy = model.evaluate(X_test, y_test, verbose=0)
print(f'\nPrecisão do modelo: {accuracy:.4f}')

# Passo 6: Fazer Previsões
# Testando com um novo exemplo de flor.
new_flower_data = np.array([[5.1, 3.5, 1.4, 0.2]])
new_flower_scaled = scaler.transform(new_flower_data)
```

```
# Fazendo a previsão.
new_prediction = model.predict(new_flower_scaled)
predicted_class = np.argmax(new_prediction)

# Mostrando o resultado final.
print("\nPrevisão para uma nova flor:")
print(f'  - Características: {new_flower_data[0]}')
print(f'  - Espécie prevista: {iris.target_names[predicted_class]}')
```

Os prints do código estão disponíveis nas imagens a seguir:

Imagem 1 – Print da primeira parte do Código dentro do programa

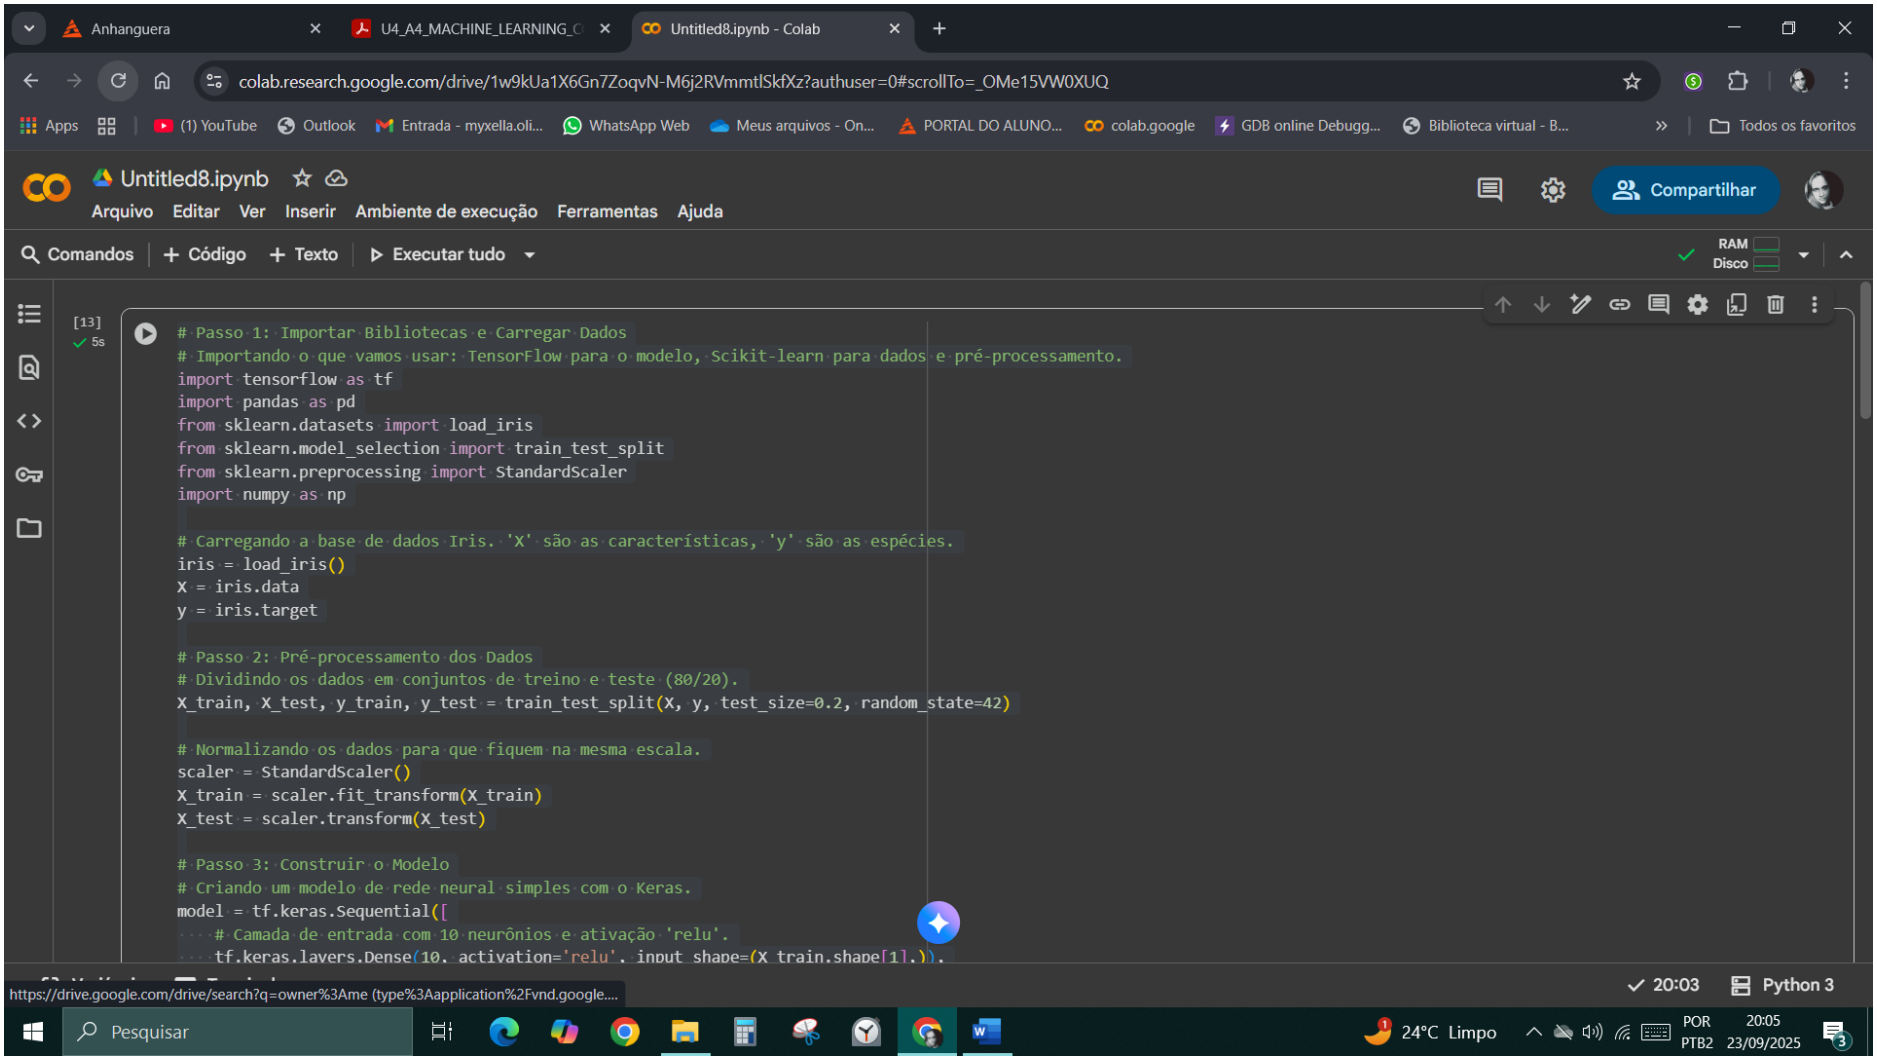


Imagem 2 – Print da segunda parte do Código dentro do programa

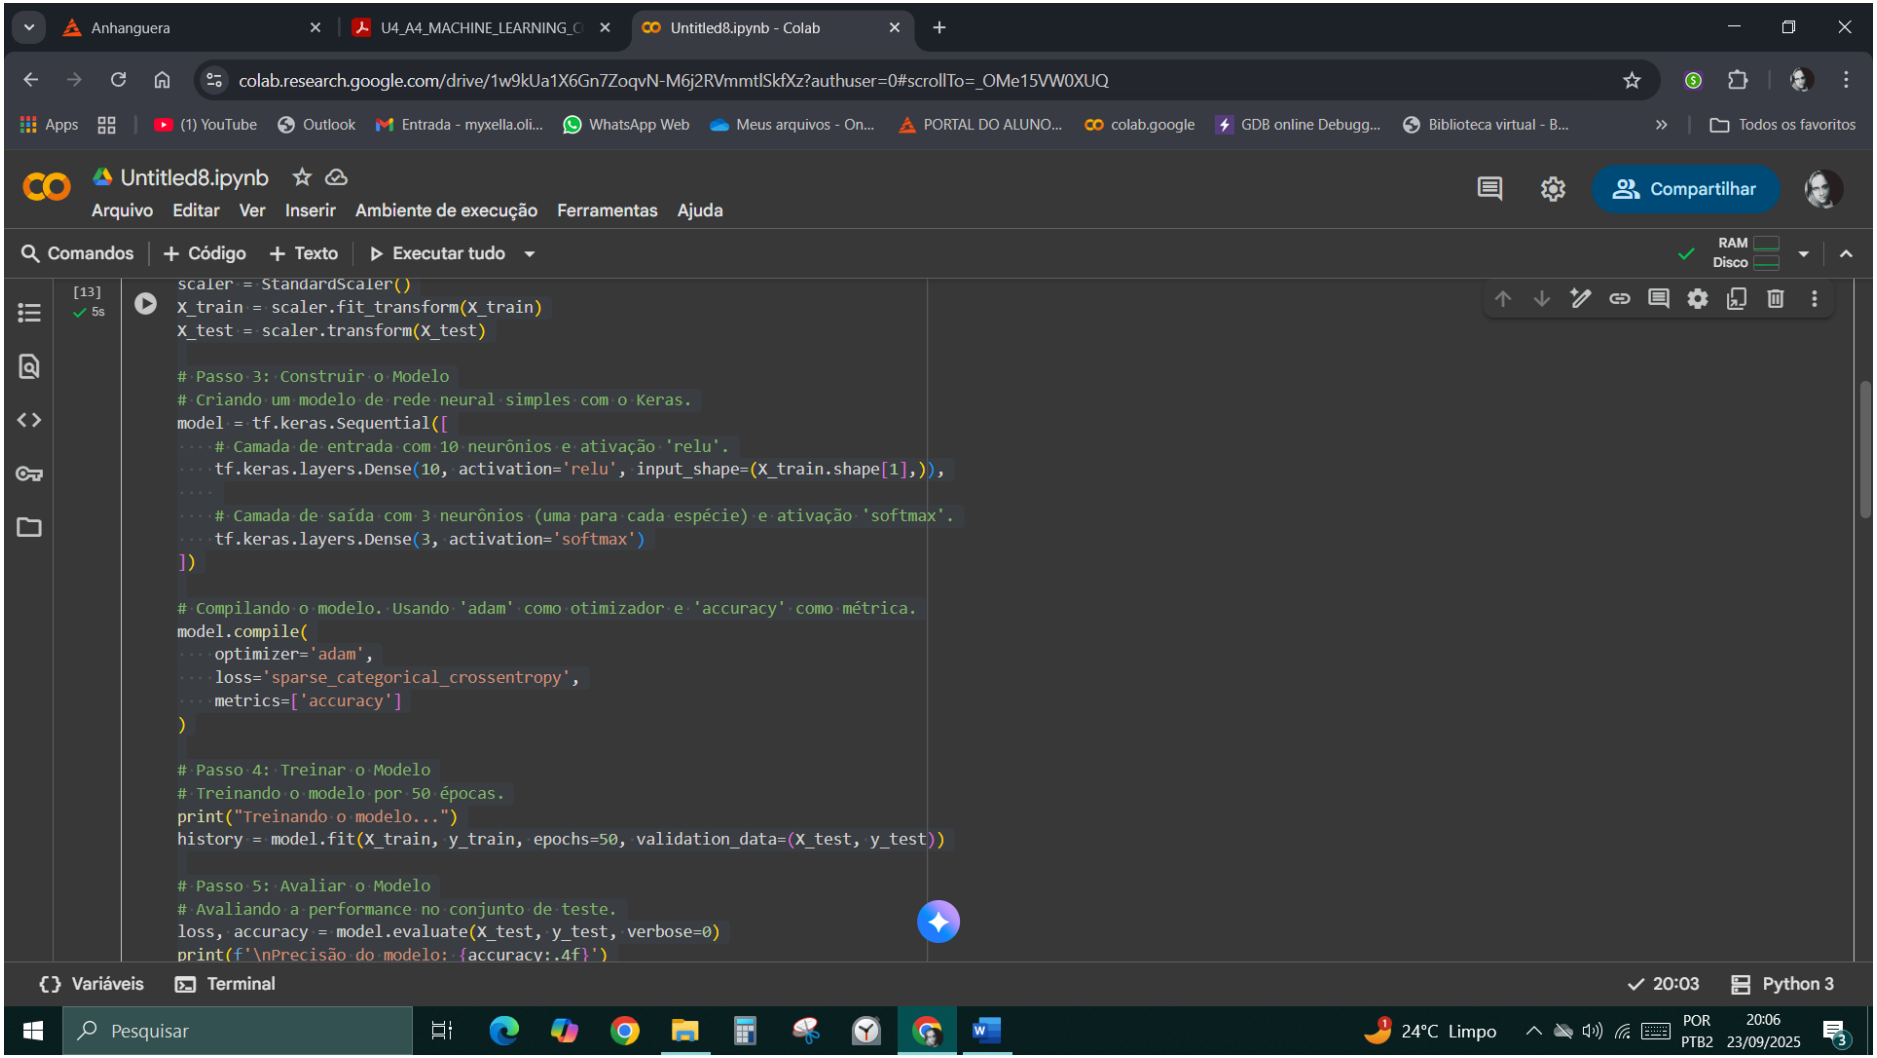


Imagem 3 – Print da terceira parte do código dentro do programa

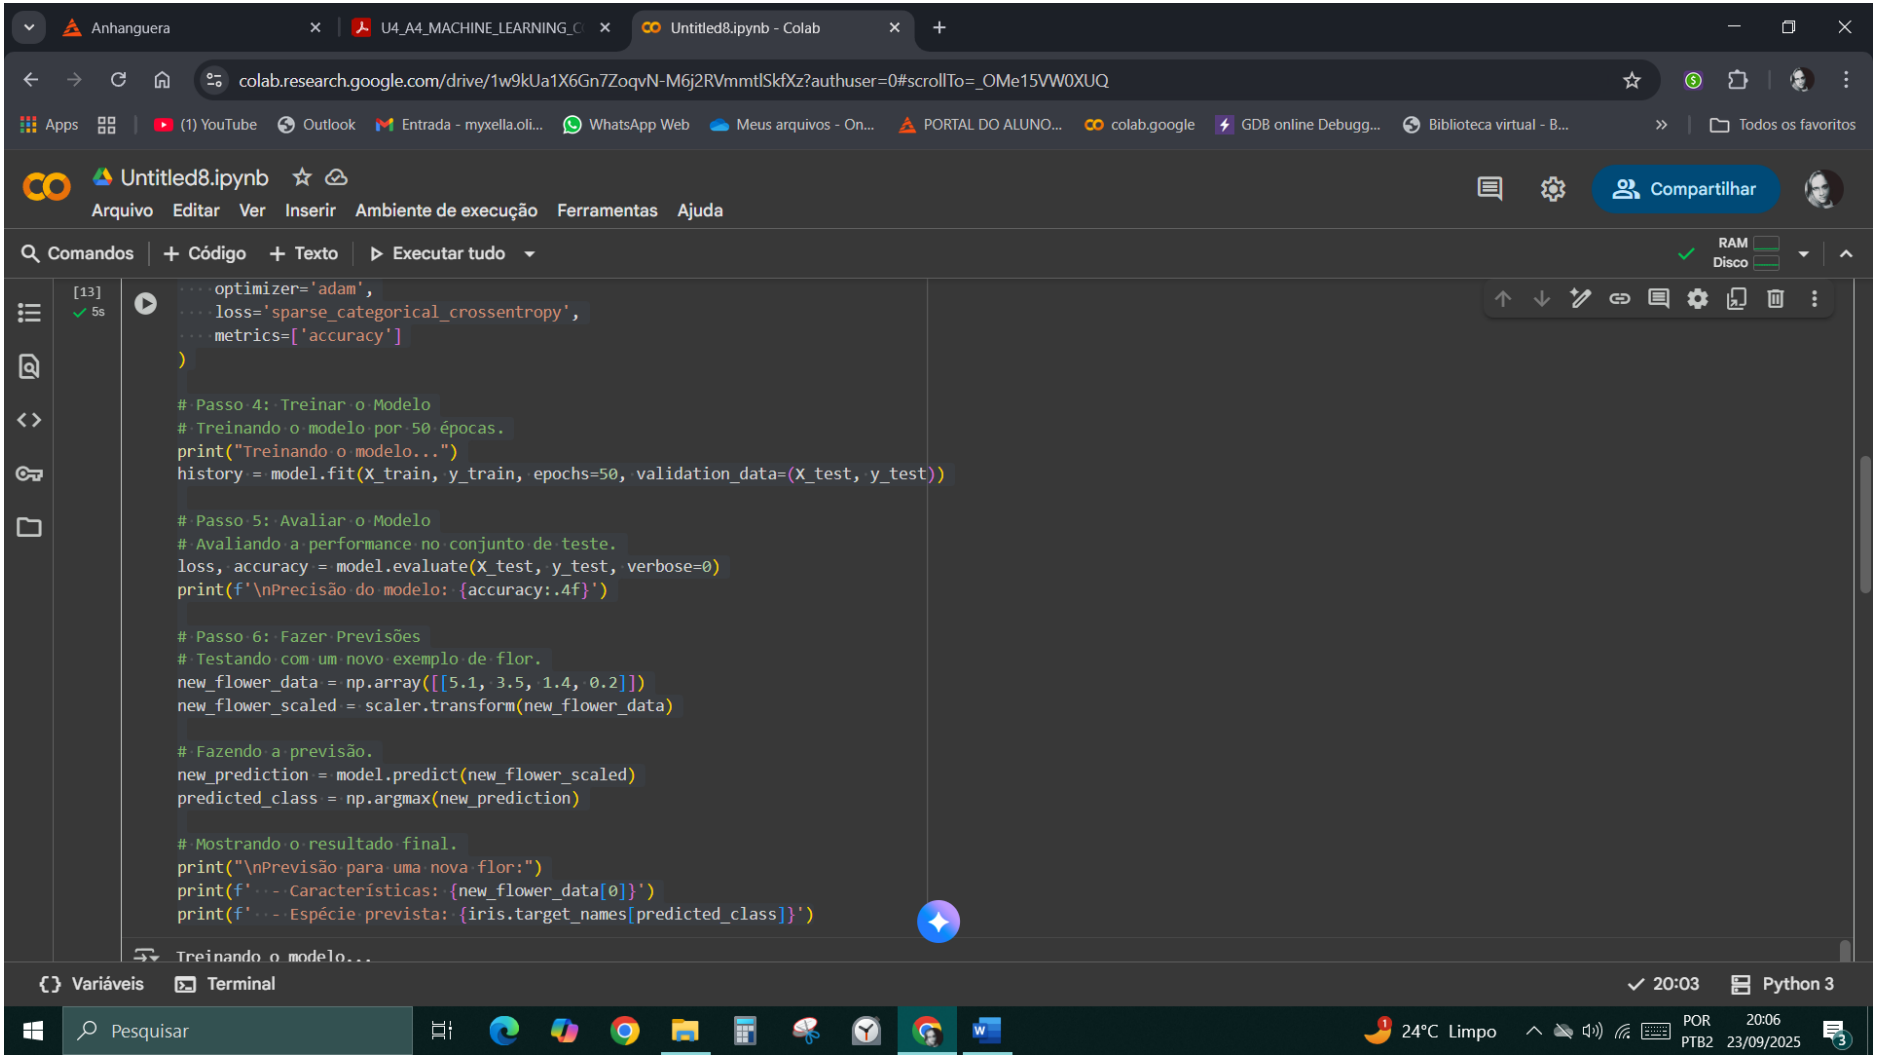


Imagem 4 – Print da primeira parte da excussão do programa

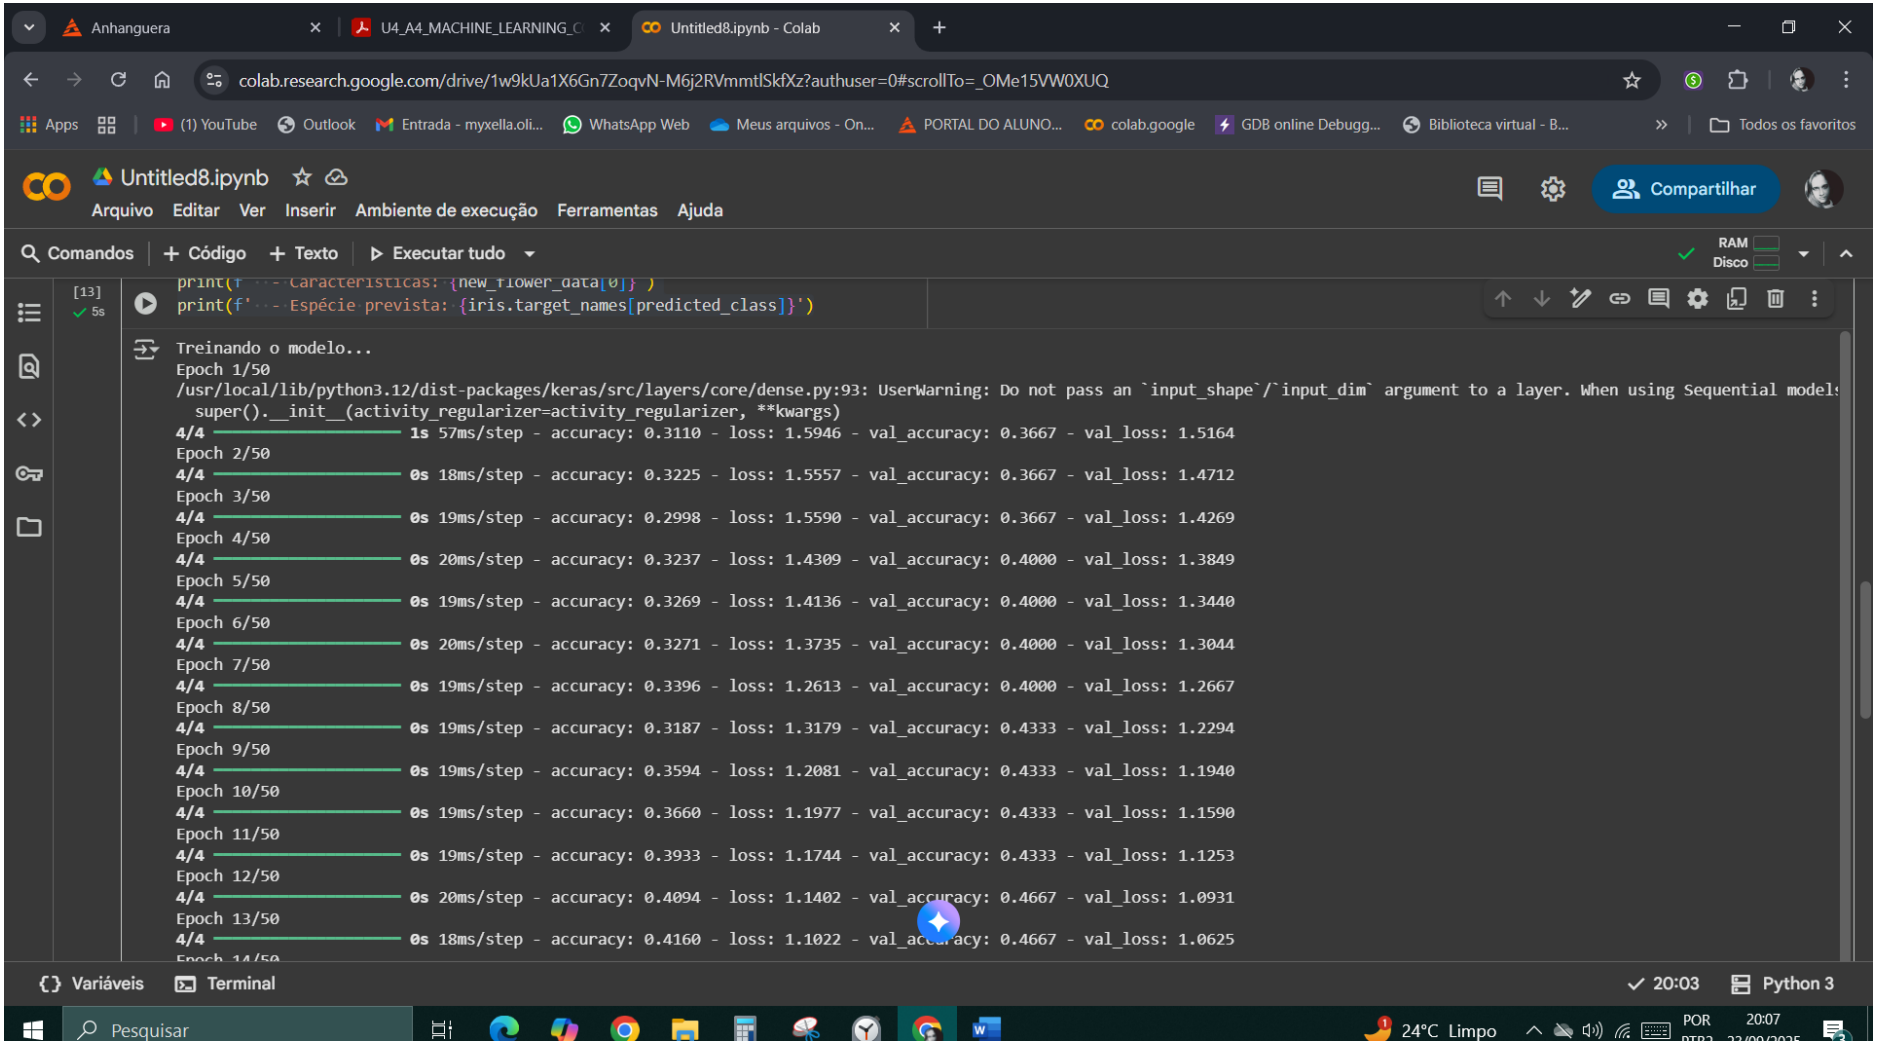


Imagem 5 – Print da segunda parte da excussão do programa

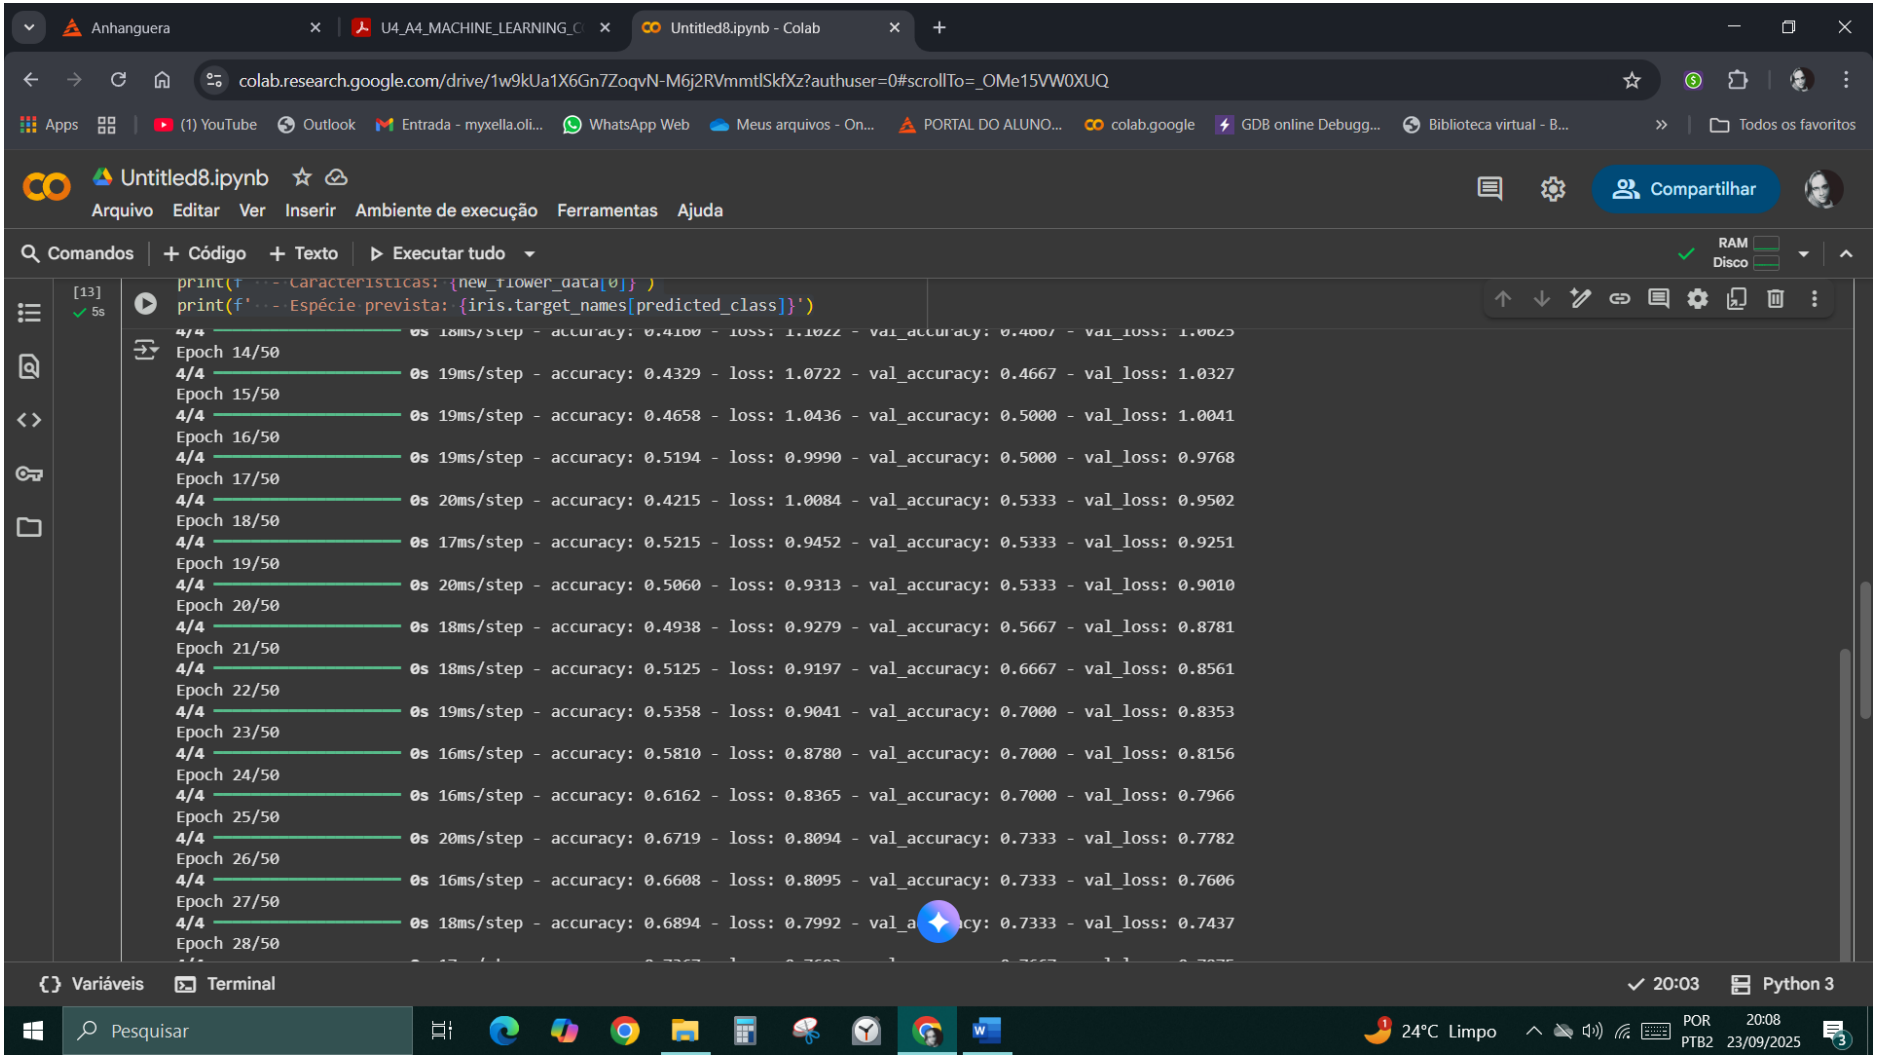


Imagem 6 – Print da terceira parte da excussão do programa

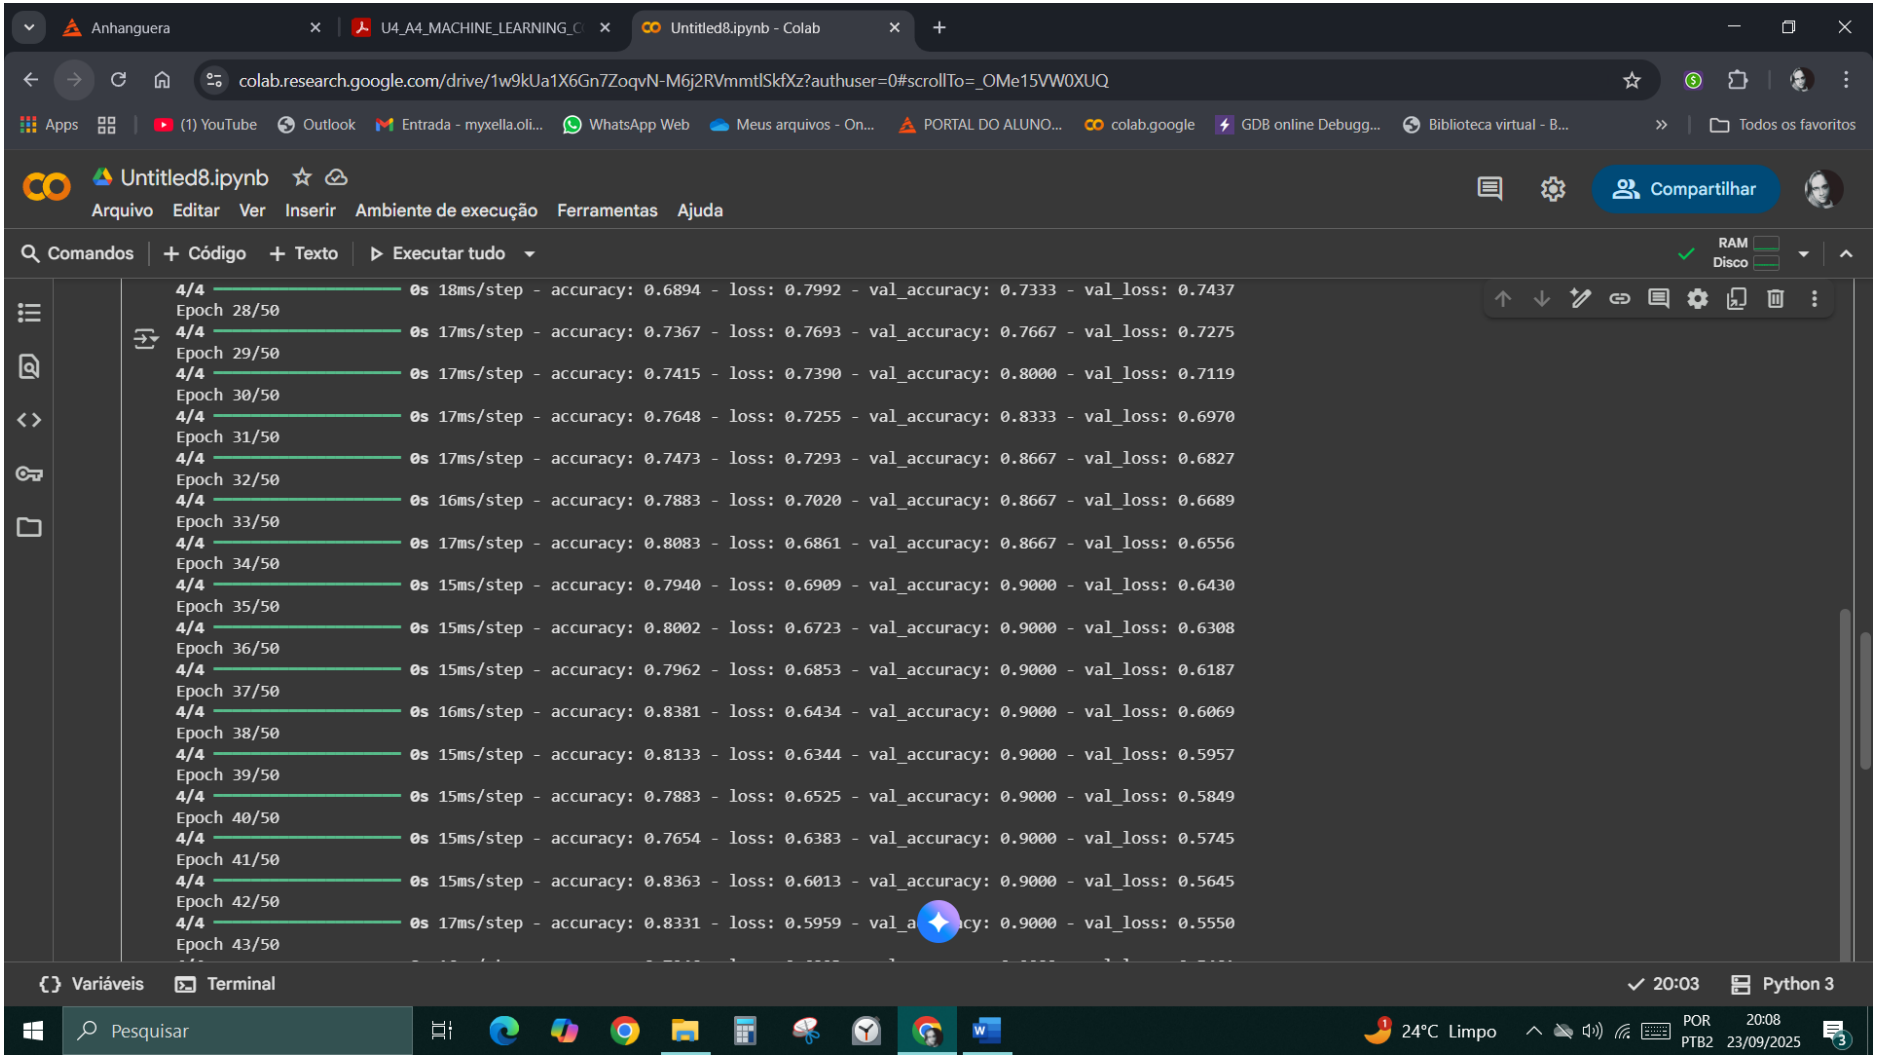
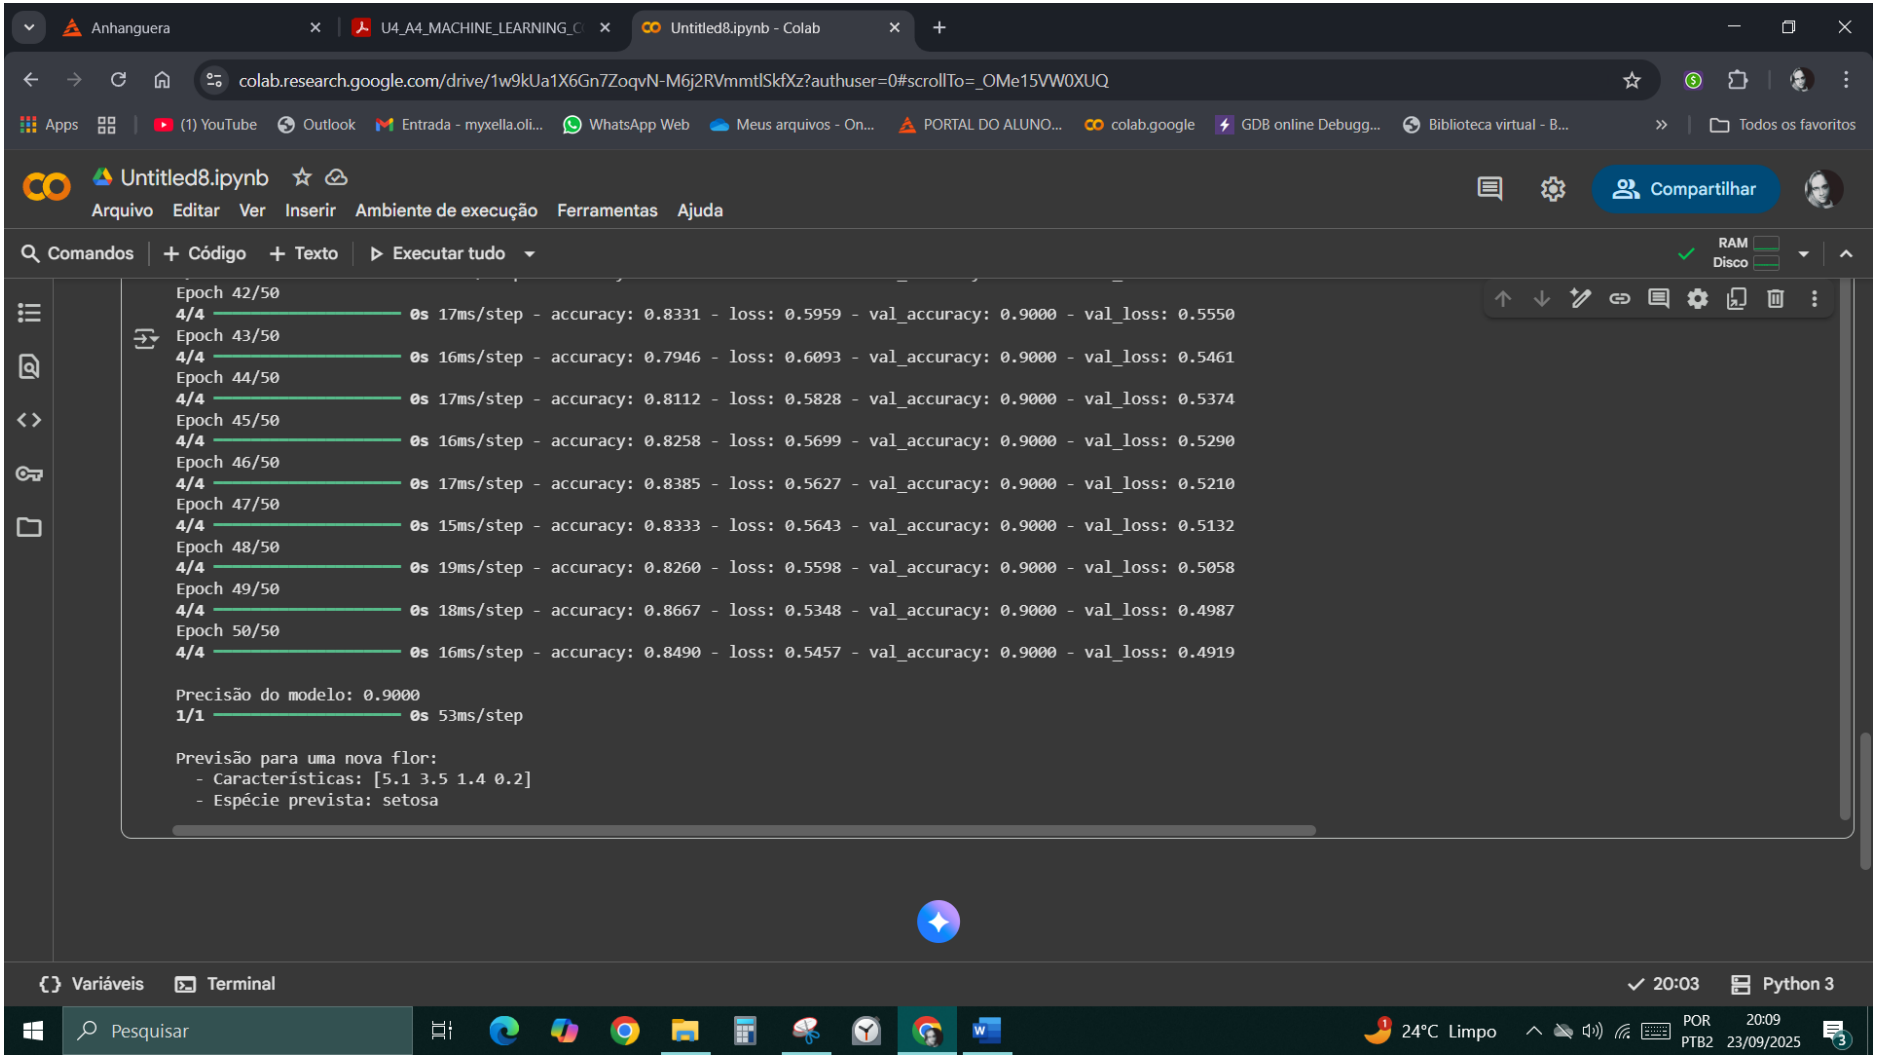


Imagem 7 – Print da quarta parte da excussão do programa



4. CONCLUSÃO

Esta aula prática proporcionou o conhecimento e aplicação de como ocorre os processos de trabalho e de dados para aplicação de uma machine learning. Para facilitar o desenvolvimento do código foi utilizado TensorFlow e o Keras para construção neural. Depois, houve ainda o treinamento, avaliação dos dados disponíveis. O objetivo final do projeto foi fazer previsões, utilizando assim um modelo treinado para classificar novas amostras de dados, no caso as flores (AMÍLCAR NETTO; MACIEL, 2021).

5. REFERENCIAS BIBLIOGRAFIAS

AMÍLCAR NETTO; MACIEL, F. Python para data science e machine learning descomplicado. Rio de Janeiro: Alta Books, 2021. E-book.